

卒業研究の紹介・自己紹介

中部大学大学院 工学研究科 情報工学専攻 修士1年 機械知覚&ロボティクスグループ (MPRG) 今井 孝洋

<http://mprg.jp>



MPRG

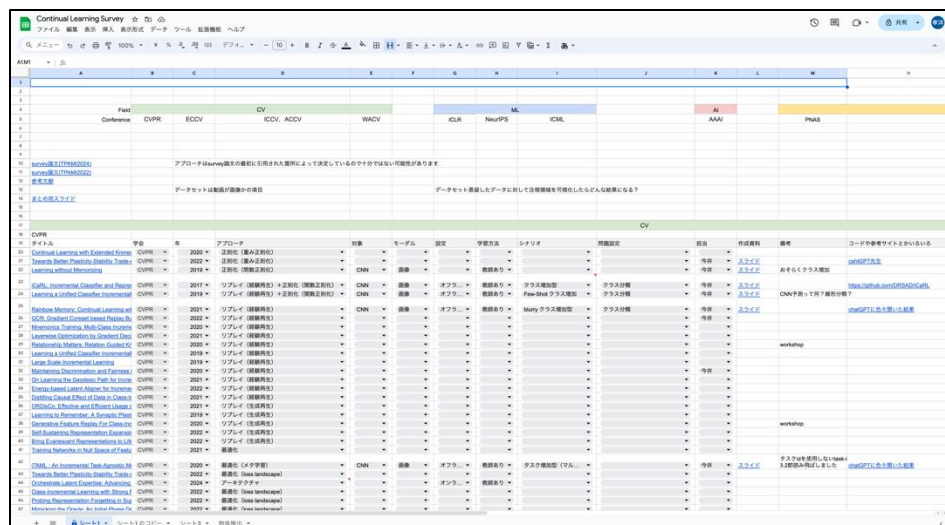
MACHINE PERCEPTION AND ROBOTICS GROUP

今井孝洋 Imai Koyo

中部大学 工学研究科 情報工学専攻 修士1年 山下研究室所属

研究テーマ：自己教師ありオンライン継続学習，継続学習

最近興味のある研究テーマ：世界モデル

The image shows a screenshot of a Google Sheet titled "Continual Learning Survey". It contains a list of research papers related to continual learning, organized into columns for conference, year, title, authors, and keywords. The papers are listed in a table format with alternating row colors.


[継続学習サーベイ-スプレッドシート](#)

Bridging Non Co-occurrence with Unlabeled In-the-wild Data for Incremental Object Detection [N. Dong+, NeurIPS'21]

概要 MPRG

- クラス増加型教師あり物体検出における実世界の非共起性に対処した手法を提案
 - 非共起性：旧タスクのクラスが新タスクのデータに存在しない
 - ➡ 既存手法は新タスクに過去タスクのクラスが存在すること（共起性）を前提

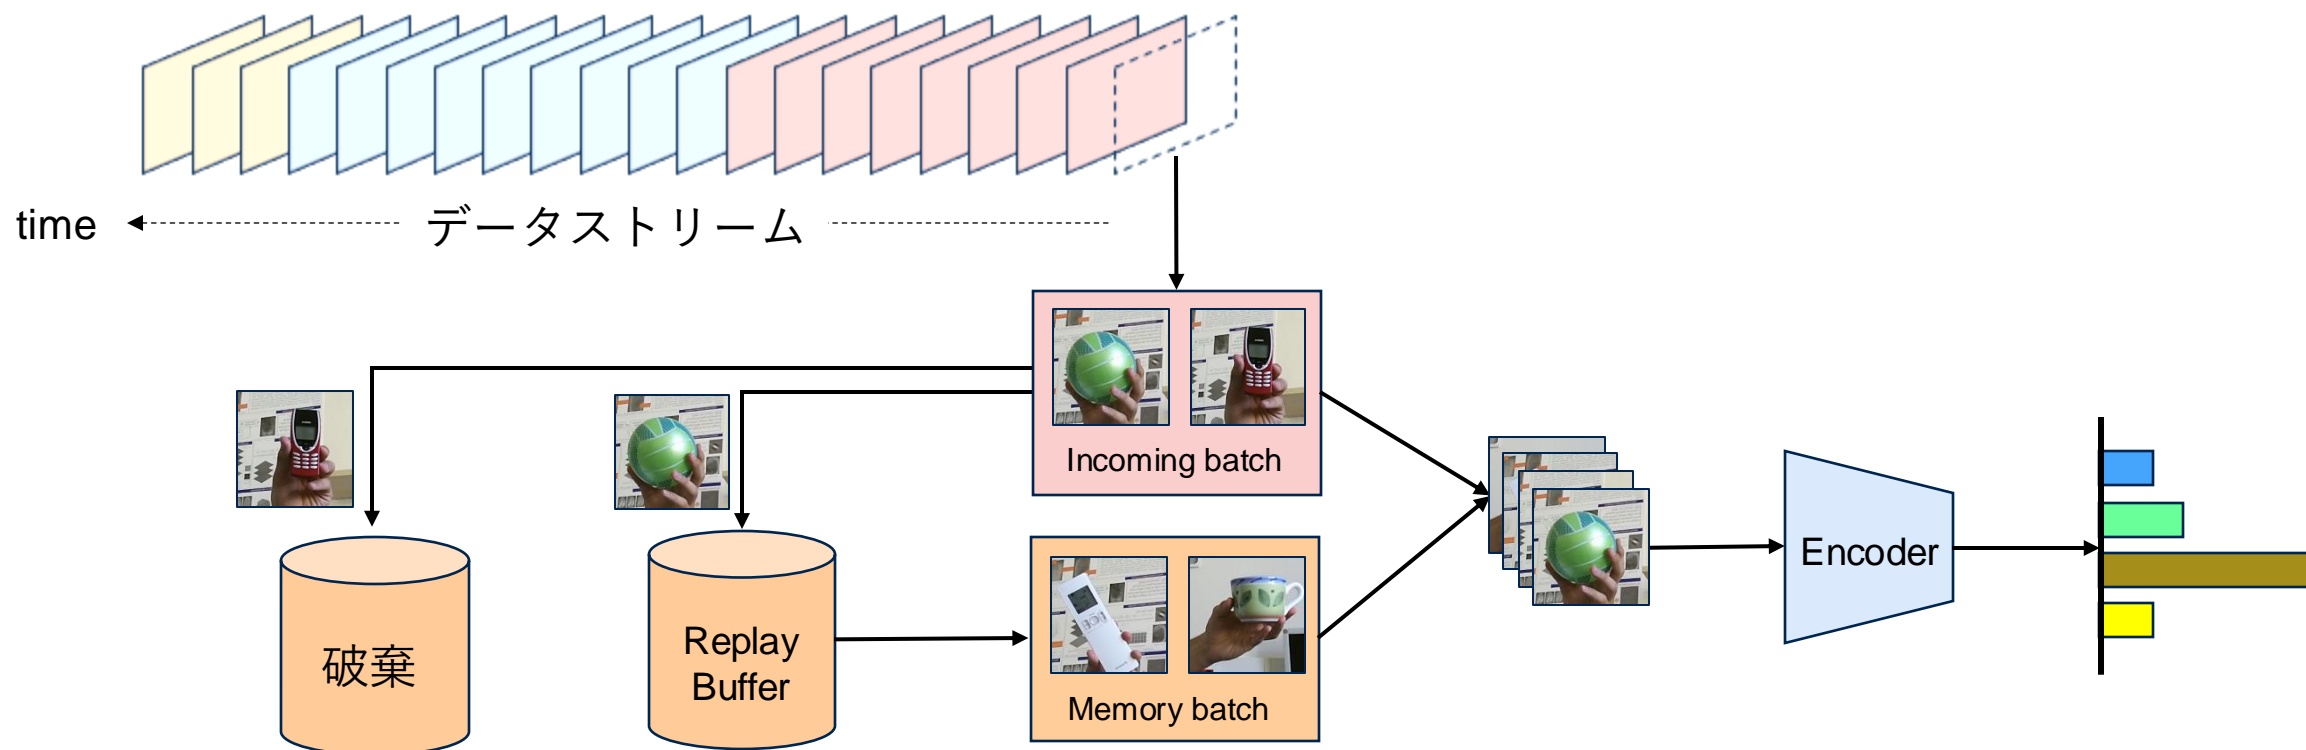
- 実世界の非共起性に対処するため大量のラベルなしデータを使用
 - ブラインドサンプリング戦略によって関連性の高いデータをin the wildなデータから選択
 - 二重教師蒸留フレームワークによって破滅的忘却に対処




論文リンク：<https://proceedings.neurips.cc/paper/2021/file/58105b9f8a71aba09a2d99d106-Paper.pdf>

[継続学習サーベイ-スライド](#)

- データストリームに対して継続的にモデルを学習する方法
 - データ分布は非定常で無限に増加
 - 到着したデータを逐次的に学習
 - 学習に使用したデータはリプレイバッファに保存, もしくは破棄



- データストリームを使用して継続的に学習する方法
 - データ分布は非定常で無限に増加
 - 到着したデータを逐次的に学習
 - 学習に使用したデータはリプレイバッファに保存, もしくは破棄



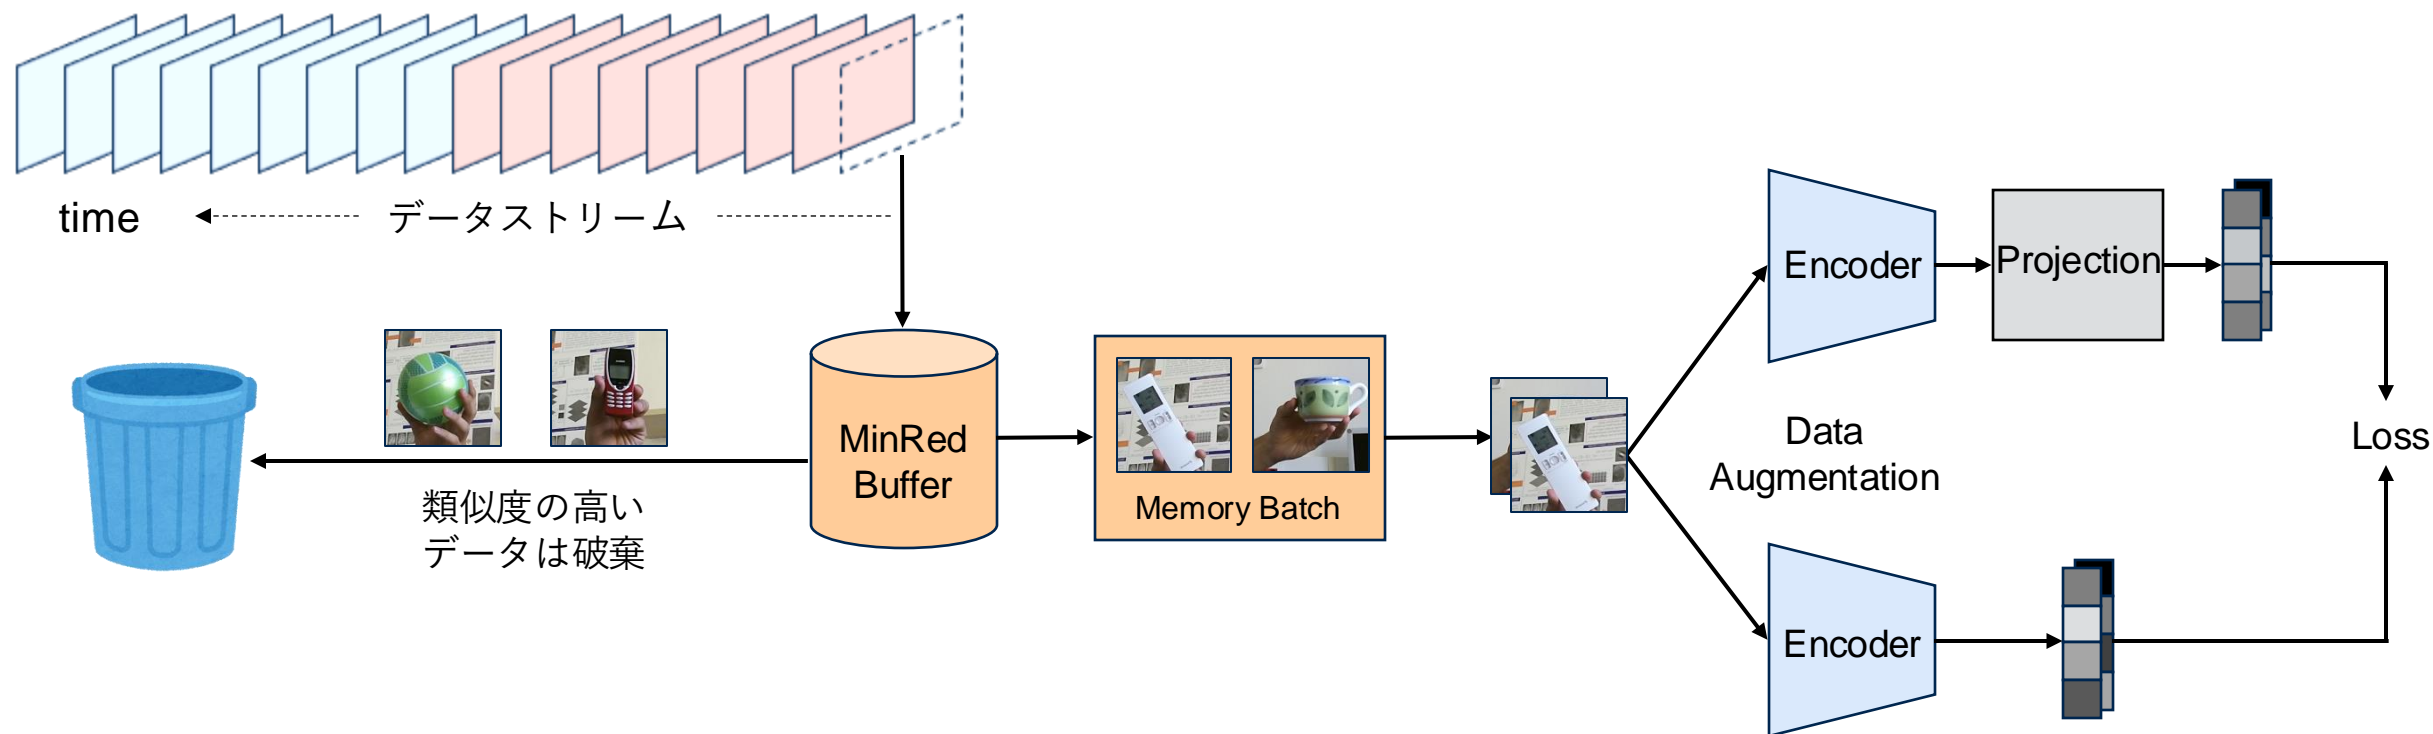
既存のオンライン継続学習法の多くはラベルありデータを対象
実世界のデータストリームはアノテーションされていない



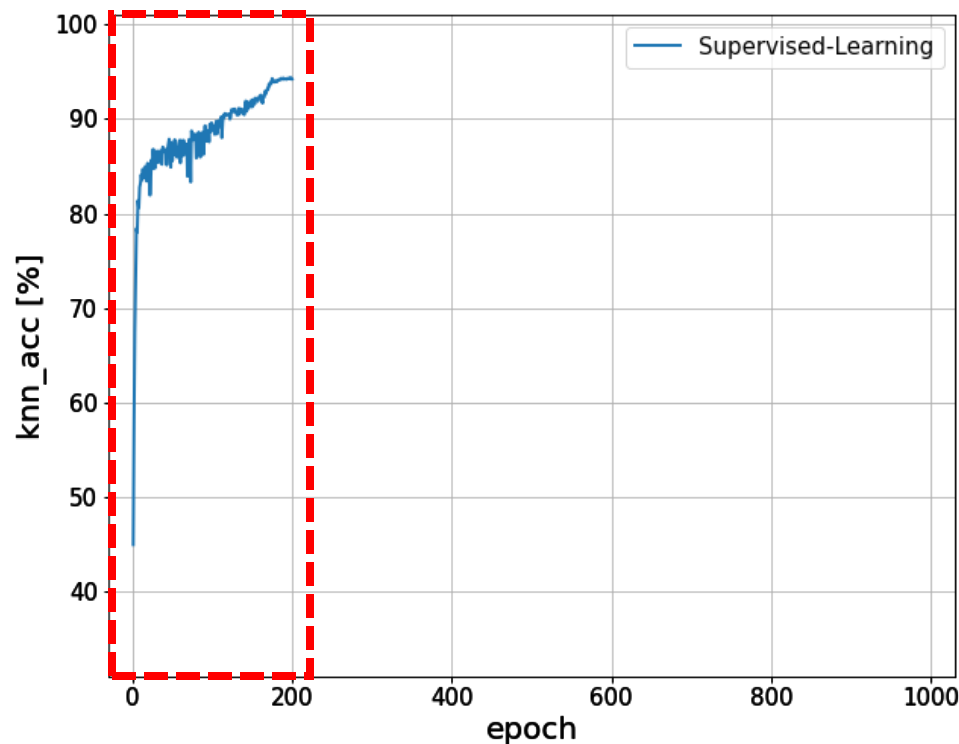
実世界のデータストリームから直接教師あり学習を行うことは困難



- リプレイバッファを使用した**自己教師あり**オンライン継続学習法
 - コサイン類似度を使用したデータ選択により冗長なデータでの学習を回避
 - 自己教師あり学習法 SimSiam を使用することでラベルなしデータを用いた学習が可能



- 自己教師あり学習は教師あり学習と比較して収束が遅い



モデル : ResNet-18
データセット : CIFAR10
評価方法 : k-NN

200エポック学習時, 教師あり学習の精度は94%

1,000エポック学習時, SimSiam は87% → 教師あり学習に追いつくにはさらに学習が必要

- 自己教師あり学習は教師あり学習と比較して収束が遅い



オンライン継続学習ではデータ分布が変化



収束の遅い従来の自己教師あり学習では
各データ分布が変化する前に学習を収束させることは困難

200エポック学習時, 教師あり学習の精度は94%, SimSiam は70%

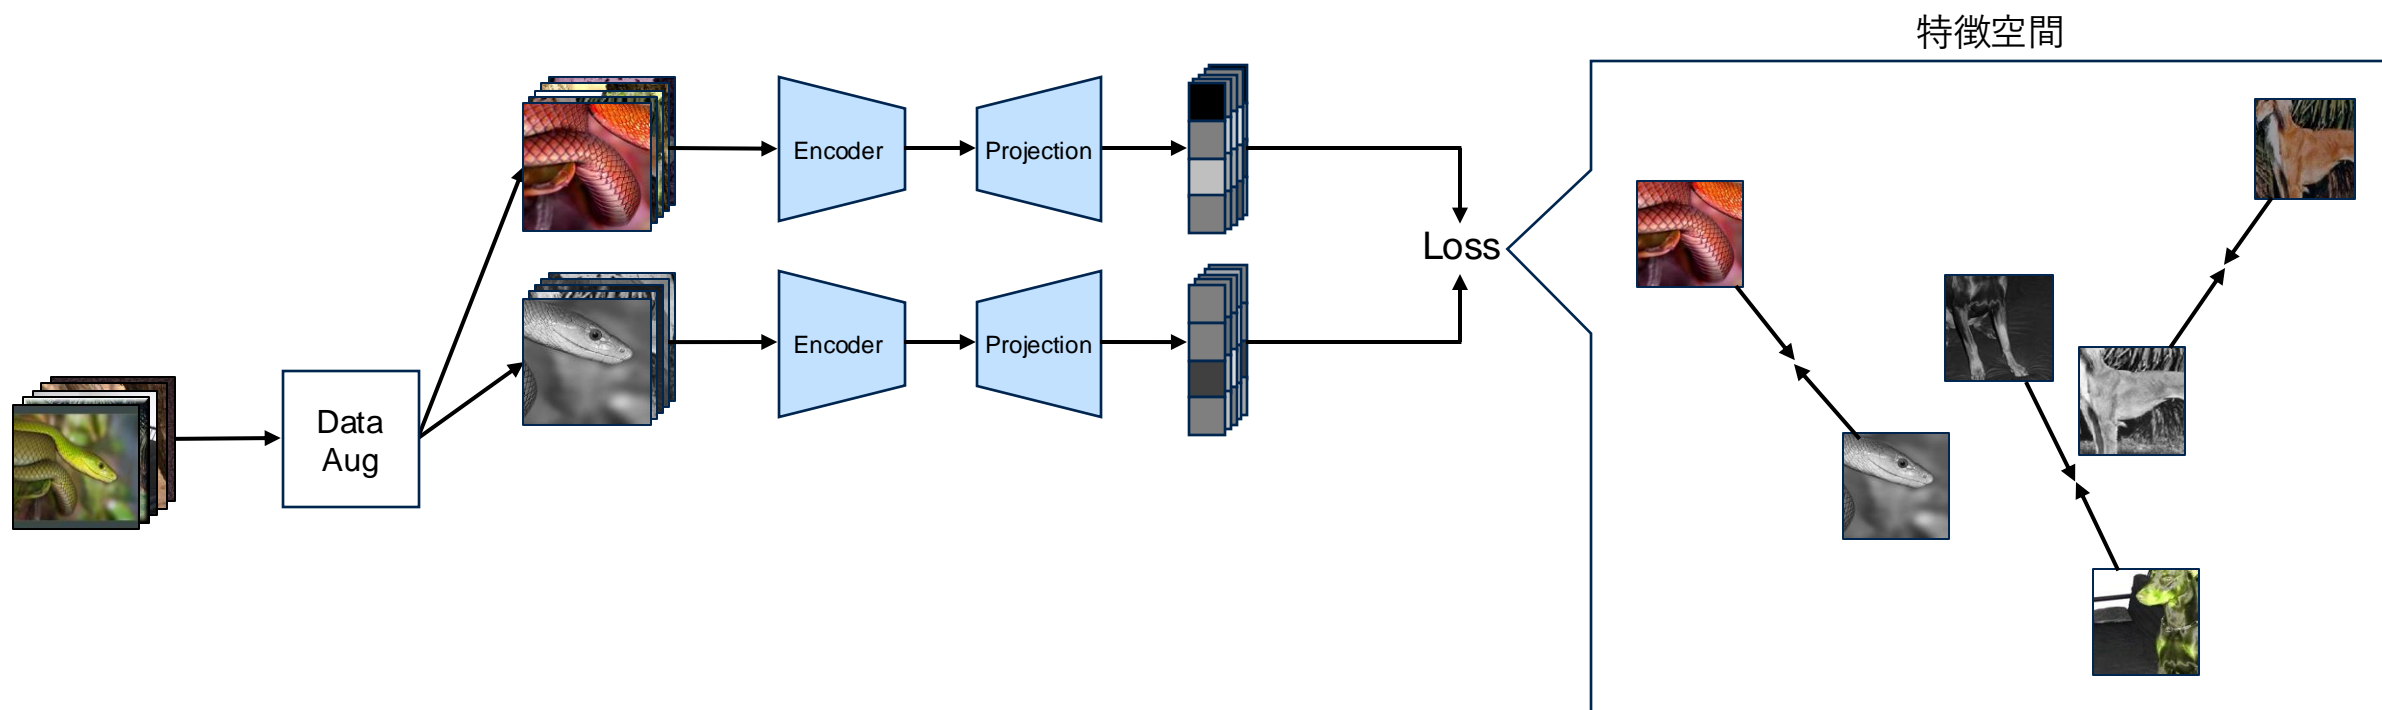
1,000エポック学習時, SimSiam は87% → 教師あり学習に追いつくにはさらに学習が必要

- データストリームに適応する自己教師ありオンライン継続学習法の実現
- アプローチ
 - 自己教師あり学習の収束の遅さに対処したEMP-SSLを利用
 - Contrastive Loss を導入した EMP-SSL によるより良い特徴表現の獲得

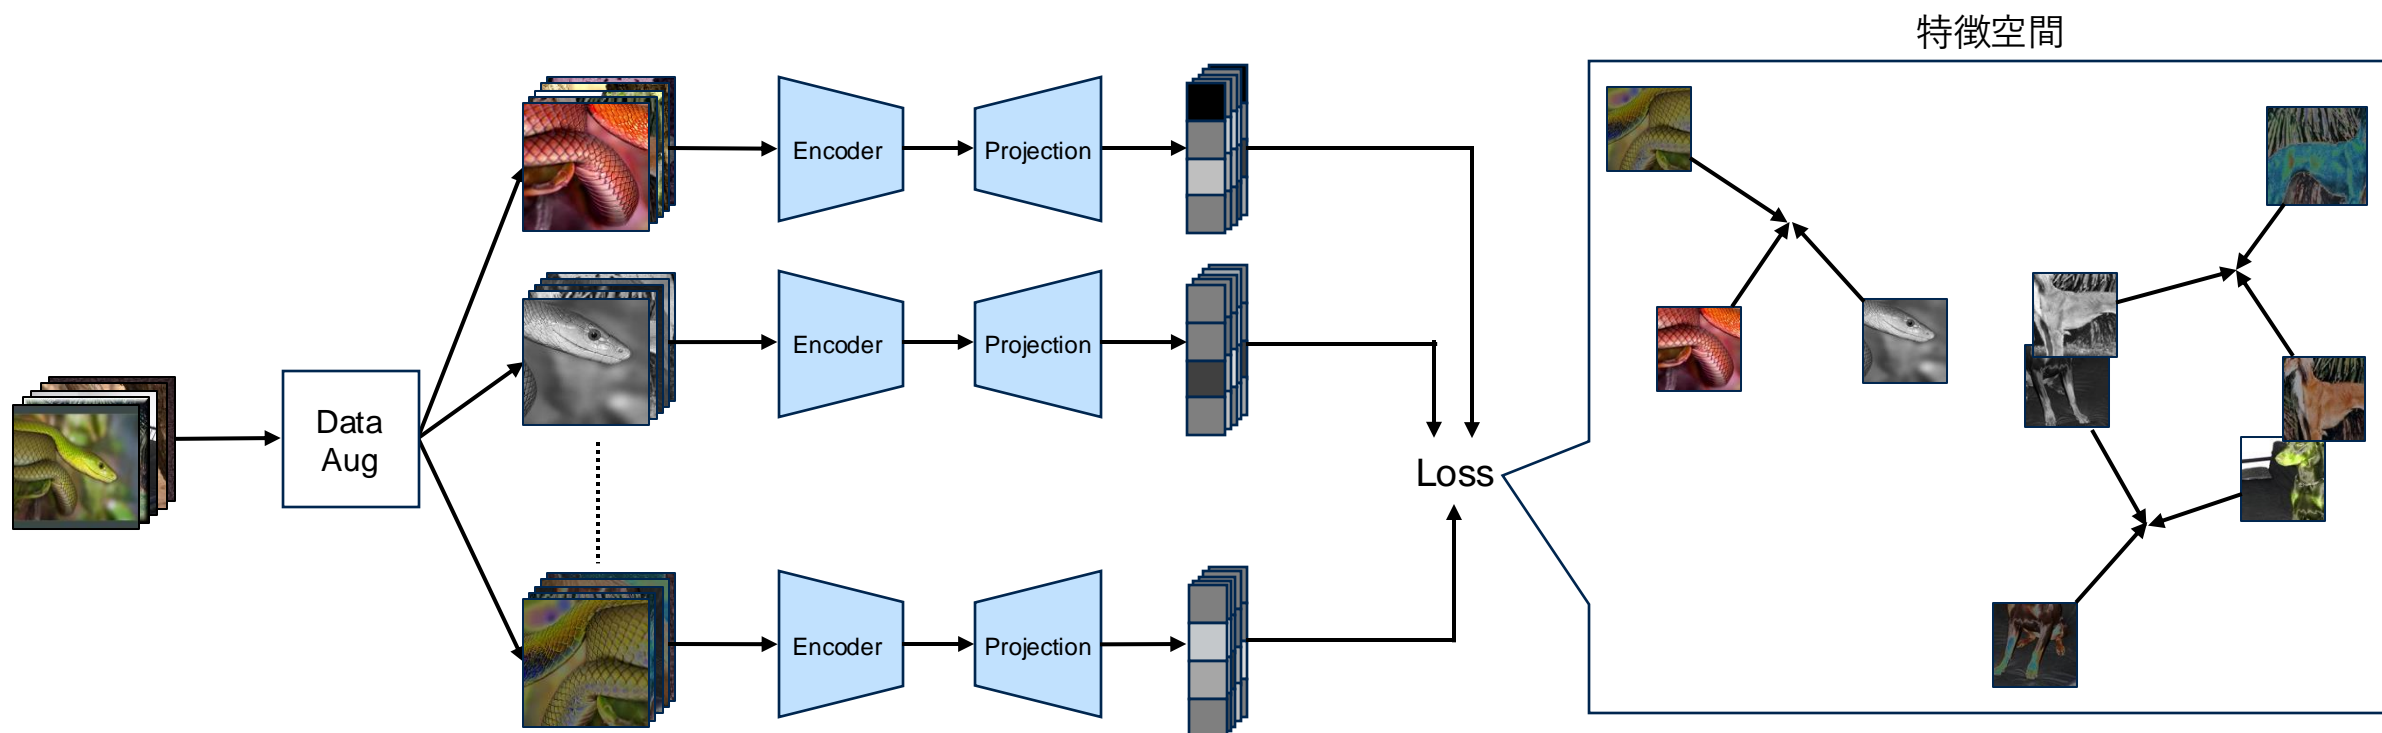
Extreme-Multi-Patch Self-Supervised-Learning (EMP-SSL)

[S. Tong+, arXiv'23]

- 自己教師あり学習の収束の遅さに対処した手法
 - データ拡張によるパッチ数を増加させることで収束を高速化
 - 1エポックで学習可能

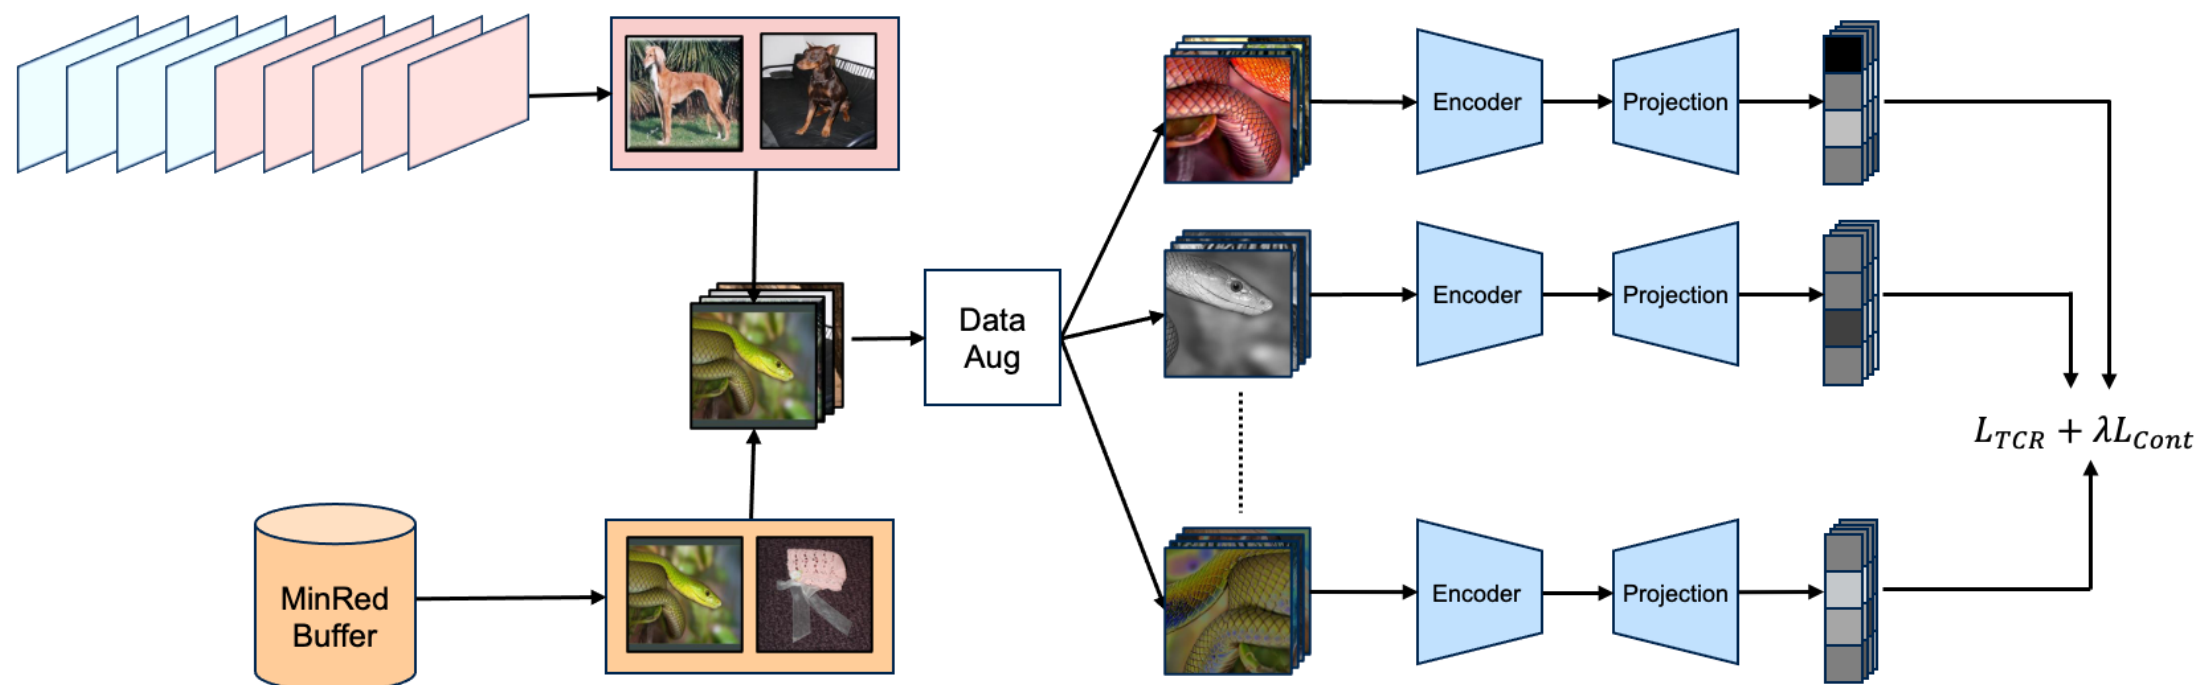


- 自己教師あり学習の収束の遅さに対処した手法
 - データ拡張によるパッチ数を増加させることで収束を高速化
 - 1エポックで学習可能



提案手法：Contrastive Loss を導入した EMP-SSL

- MinRed をベースに Contrastive Loss を導入した EMP-SSL



- 提案手法の損失関数
 - EMP-SSL の損失に Contrastive Loss を追加

$$\mathcal{L} = \sum_{i=1, \dots, n} \left(\underbrace{\frac{1}{n} \mathcal{L}_{TCR}(Z_i)}_{\text{EMP-SSLの損失}} + \underbrace{\frac{\lambda}{nb} \sum_{j=1, \dots, b} \mathcal{L}_{Cont}(\bar{z}^j, z_i^j)}_{\text{Contrastive Loss}} \right)$$

$$\mathcal{L}_{TCR}(Z) = -\frac{1}{2} \log \det \left(I + \frac{d}{b\epsilon^2} ZZ^T \right)$$

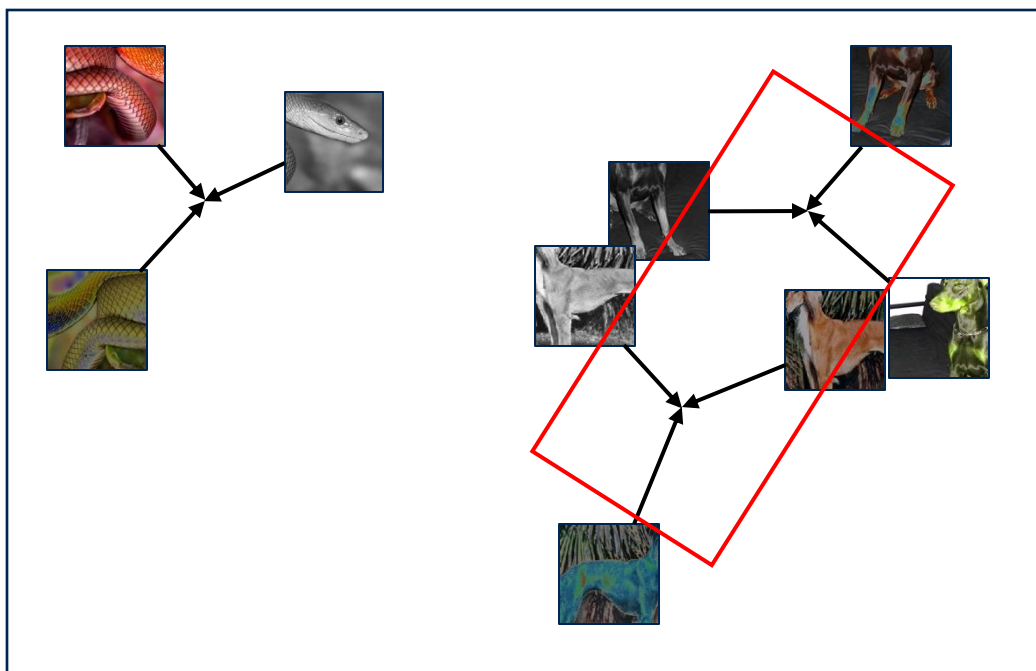
$$\mathcal{L}_{Cont}(\bar{z}^j, z_i^j) = -\log \frac{\exp(\bar{z}^j \cdot z_i^j / \tau)}{\sum_{k=1}^n \sum_{l=1, l \neq j}^b \exp(\bar{z}^j \cdot z_k^l / \tau)}$$

n : パッチ数
 λ : Contrastive Loss の重み
 z : データの特徴量
 \bar{z} : 各データの特徴量の平均
 I : 単位行列
 b : バッチサイズ
 d : 投影次元数
 ϵ : 歪み選択のパラメータ
 τ : 温度パラメータ

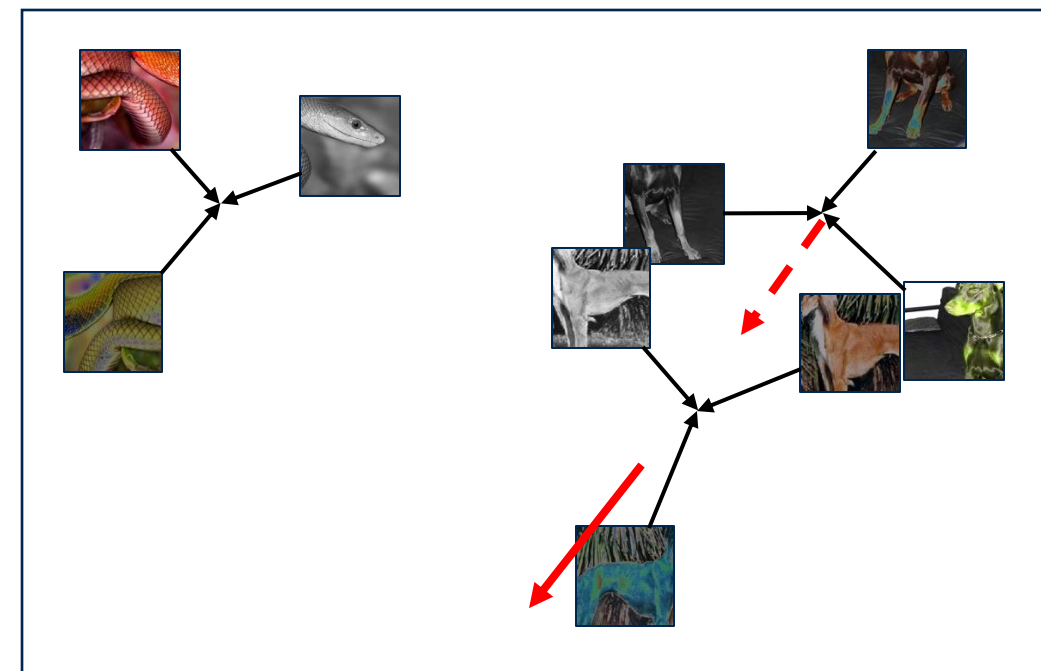
- 複数パッチの利用
 - 各データのパッチ毎の特徴量を一度に集合・分離

$$\mathcal{L}_{Cont}(\bar{z}^j, z_i^j) = -\log \frac{\exp(\bar{z}^j \cdot z_i^j / \tau)}{\sum_{k=1}^n \sum_{l=1, l \neq j}^b \exp(\bar{z}^j \cdot z_k^l / \tau)}$$

z : データの特徴量
 \bar{z} : 各データの特徴量の平均
 n : パッチ数
 b : バッチサイズ
 τ : 温度パラメータ



EMP-SSL



提案手法


- 従来手法と提案手法による分類精度の比較
 - 学習終了時と学習過程の観点から提案手法を評価
- 実験条件
 - 比較対象
 - MinRed : 従来手法
 - EMP-SSL : 学習法を EMP-SSL に変更した MinRed
 - データセット
 - Seq-CIFAR10 : 1クラス × 10タスク
 - Seq-CIFAR100 : 5クラス × 20タスク
 - Seq-ImageNet100 : 10クラス × 10タスク
 - 評価方法
 - k-NN法

	Seq-CIFAR10	Seq-CIFAR100	Seq-ImageNet100
MinRed	41.09	22.56	21.90
EMP-SSL	57.64	27.18	26.06
提案手法	60.04	30.28	26.58

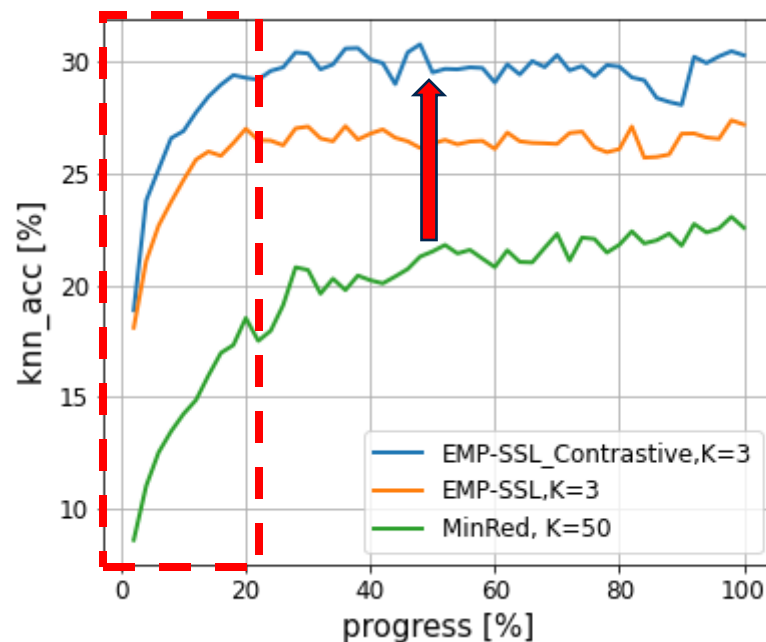
Accuracy improvements from MinRed to the proposed method:

- Seq-CIFAR10: +18.95pt
- Seq-CIFAR100: +7.72pt
- Seq-ImageNet100: +4.68pt

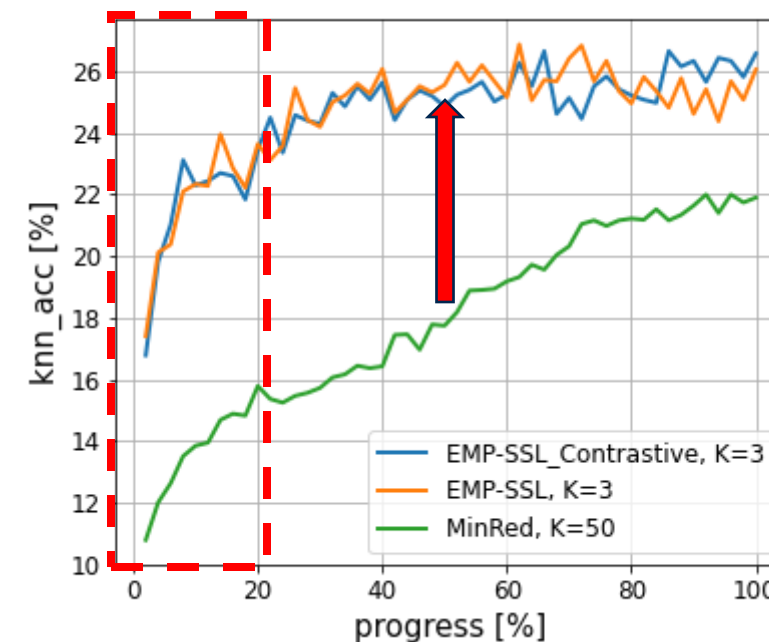
- 提案手法は従来手法に比べ精度向上
 - EMP-SSL にContrastive Loss を導入することは有効



Seq-CIFAR10



Seq-CIFAR100



Seq-ImageNet100

- 学習過程における精度向上
 - 提案手法は学習序盤から高い精度を達成



学習収束が早くなり，学習全体を通して高精度

- Contrastive Lossを導入したEMP-SSLによるオンライン継続学習を提案
 - 提案手法は従来手法と比較して収束速度の向上を確認
 - 収束速度改善による精度向上を確認
- 今後の展望
 - 損失関数の再検討
 - ファインチューニングでの比較
 - オフライン継続学習での比較